



ĐẠI HỌC ĐÀ NẴNG

TRƯỜNG ĐẠI HỌC BÁCH KHOA

D
BACH KHOA

TRÍ TUỆ NHÂN TẠO

N
A
N
G



Khoa Công Nghệ Thông Tin

TS. Nguyễn Văn Hiệu

TRÍ TUỆ NHÂN TẠO

Bài 12-13:

Logistic Regression


D
BACH KHOA

N
A
N
G

Nội dung

- Giới thiệu
- Logistic Regression Model
- Hàm giả thuyết
- Bài toán phân lớp
- Hàm mất mát
- Tối ưu hàm mất mát
- Demo
- Bài tập

Giới thiệu






Giới thiệu(tiếp)

- Ví dụ bài toán phân lớp
 - Email Spam/Not Spam: Thư nào nên bỏ vào thùng rác?
 - Tumor benign/malignant: Ung thư lành tính hay ác tính?
 - Online Transactions: Giao dịch lừa đảo hay không ?
- $y \in \{0, 1\}$
 - 0: “lớp âm”(negative class) [có nghĩa: ung thư lành tính]
 - 1: “lớp dương”(positive class) [có nghĩa : ung thư ác tính]
- Bài toán phân lớp:
 - 0|1 - Phân lớp nhị phân
 - $y \in \{0, 1, 2, 3, 4, \dots\}$

Giới thiệu(tiếp)

- Làm thế nào để phát triển thuật toán phân lớp ?
- Ví dụ:



- Dự đoán cần đặt ngưỡng $h_{\theta}(x) = \theta^T x = \begin{cases} \geq 0.5 & y = 1 \\ < 0.5 & y = 0 \end{cases}$
- Hàm giả thuyết của LR không sử dụng cho bài toán phân lớp.


Giới thiệu(tiếp)

- Tác vụ: $Y = 0$ hoặc $Y = 1$
- Linear Regression: $h_{\theta}(x) < 0 \ || \ h_{\theta}(x) > 1$
- Logistic Regression: $0 \leq h_{\theta}(x) \leq 1$

Logistic Regression Model

- Linear Regression: $h_{\theta}(x) = \theta^T x$
- Logistic regression: $h_{\theta}(x) = g(\theta^T x), g(z) = \frac{1}{1 + e^{-z}}$
 - $g(z)$ hàm sigmoid hay hàm logistic

- Trực quan:



- Dự đoán:
 - $y = 1$, nếu $h_{\theta}(x) \geq 0.5$, hay $y = 1$, nếu $\theta^T x \geq 0$
 - $y = 0$, nếu $h_{\theta}(x) < 0.5$, hay $y = 0$, nếu $\theta^T x < 0$

$$h_{\theta}(x) = 0.5 \mid \theta^T x = 0$$

**Ranh giới quyết định
(decision boundary)**

Hàm giả thuyết(hypothesis)

- Diễn giải hàm giả thuyết: $h_{\theta}(x) = g(\theta^T x) = \frac{1}{1 + e^{-\theta^T x}}$
 - $h_{\theta}(x)$ = xác suất để $y = 1$ với dữ liệu input x

- Ví dụ (muốn phân loại khối u)


$$x = \begin{bmatrix} x_0 \\ x_1 \end{bmatrix} = \begin{bmatrix} 1 \\ size \end{bmatrix}, h_{\theta}(x) = 0.7$$

- Xác suất để $y = 1$ là 0.7
 - Nói cách khác: 70% là ác tính, 30 % là lành tính.
- $h_{\theta}(x) = g(\theta^T x) = P(y = 1/x; \theta)$

$$P(y = 1/x; \theta) + P(y = 0/x; \theta) = 1$$
$$P(y = 0/x; \theta) = 1 - h_{\theta}(x)$$

Hàm giả thuyết(tiếp)

- Giả sử tập huấn luyện




$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2)$$

$$\theta_0 = -3, \theta_1 = 1; \theta_2 = 1$$

- Áp dụng công thức
 - Dự đoán $y = 1$ nếu $-3 + x_1 + x_2 \geq 0$
 - Dự đoán $y = 0$ nếu $-3 + x_1 + x_2 < 0$
- Decision Boundary: $x_1 + x_2 = 3$
 - Đường phân vùng giữa $y = 0$ và $y = 1$
 - Tính chất của hàm giả thuyết

Hàm giả thuyết(tiếp)

- Giả sử tập huấn luyện



$$h_{\theta}(x) = g(\theta_0 + \theta_1 x_1 + \theta_2 x_2 + \theta_3 x_1^2 + \theta_4 x_2^2)$$

$$\theta_0 = -1; \theta_1 = 0; \theta_2 = 0; \theta_3 = 1; \theta_4 = 1$$

- Áp dụng công thức
 - Dự đoán $y = 1$ nếu $-1 + x_1^2 + x_2^2 \geq 0$
 - Dự đoán $y = 0$ nếu $-1 + x_1^2 + x_2^2 < 0$
- Decision Boundary: $x_1^2 + x_2^2 = 1$
 - Tính chất của hàm giả thuyết

Bài toán phân lớp

- Cho m dữ liệu để huấn luyện, toàn bộ dữ liệu thứ i chứa input $x^{(i)}$ và output $y^{(i)}$ với $y^{(i)} \in \{0, 1\}$

$x^{(1)} \rightarrow$	$x_1^{(1)}$	$\dots$	$x_n^{(1)}$	$y^{(1)}$
$x^{(2)} \rightarrow$	$x_1^{(2)}$	$\dots$	$x_n^{(2)}$	$y^{(2)}$
$\vdots$	$\vdots$		$\vdots$	$\vdots$
$x^{(m)} \rightarrow$	$x_1^{(m)}$	$\dots$	$x_n^{(m)}$	$y^{(m)}$
$x^{(new)} \rightarrow$				?????

- Tác vụ:** $h_\theta : R^{n+1} \rightarrow Y$ $h_\theta(\bar{x}) = g(\theta^T \bar{x}) = \frac{1}{1 + e^{-\theta^T \bar{x}}}$
 $\Rightarrow$ tìm vector $\theta = (\theta_0, \theta_1, \dots, \theta_n)^T$

Hàm mất mát (Loss function)

- Hồi quy tuyến tính:

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2 = \frac{1}{m} \sum_{i=1}^m \text{Cost} \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)$$

$$\text{Cost} \left(h_{\theta}(x^{(i)}) - y^{(i)} \right) = \frac{1}{2} \left(h_{\theta}(x^{(i)}) - y^{(i)} \right)^2$$

Hay


$$\text{Cost}(h_{\theta}(x) - y) = \frac{1}{2} (h_{\theta}(x) - y)^2$$

- Hàm Cost không tốt cho bài toán Logistic regression

Hàm mất mát (tiếp)

- Logistic Regression

$$Cost(h_{\theta}(x) - y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$




if $y = 1, h_{\theta}(x) = 1$, then $Cost(h_{\theta}(x), y) = 0$
if $y = 1, h_{\theta}(x) = 0$, then $Cost(h_{\theta}(x), y) = \infty$

Hàm mất mát (tiếp)

- Logistic Regression

$$Cost(h_{\theta}(x) - y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$$

Cost



$$\begin{aligned} \text{if } y = 0, h_{\theta}(x) = 0, \text{ then } & Cost(h_{\theta}(x), y) = 0 \\ \text{if } y = 0, h_{\theta}(x) = 1, \text{ then } & Cost(h_{\theta}(x), y) = \infty \end{aligned}$$

Hàm mất mát (tiếp)

- Logistic Regression

$$J(\theta) = \frac{1}{m} \sum_{i=1}^m \text{Cost}(h_{\theta}(x^{(i)}) - y^{(i)})$$

- $\text{Cost}(h_{\theta}(x) - y) = \begin{cases} -\log(h_{\theta}(x)) & \text{if } y = 1 \\ -\log(1 - h_{\theta}(x)) & \text{if } y = 0 \end{cases}$
- $\text{Cost}(h_{\theta}(x) - y) = -y \log(h_{\theta}(x)) - (1 - y) \log(1 - h_{\theta}(x))$

$$\begin{aligned} 1. & \text{if } y = 1, & \text{Cost}(h_{\theta}(x), y) &= -\log(h_{\theta}(x)) \\ 2. & \text{if } y = 0, & \text{Cost}(h_{\theta}(x), y) &= -\log(1 - h_{\theta}(x)) \end{aligned}$$

- $J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \cdot \log(h_{\theta}(x^{(i)})) + (1 - y^{(i)}) \cdot \log(1 - h_{\theta}(x^{(i)})) \right]$

Hàm mất mát (tiếp)

- Logistic Regression

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \cdot \log \left(h_{\theta} \left(x^{(i)} \right) \right) + \left(1 - y^{(i)} \right) \cdot \log \left(1 - h_{\theta} \left(x^{(i)} \right) \right) \right]$$

- Tìm θ

$$\min_{\theta} (J(\theta))$$

- Dự đoán một dữ liệu mới x :

- Kết quả

$$h_{\theta}(x) = \frac{1}{1 + e^{-\theta^T x}}$$

Tối ưu hàm mất mát

- Phương pháp tối ưu

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[y^{(i)} \cdot \log \left(h_{\theta} \left(x^{(i)} \right) \right) + \left(1 - y^{(i)} \right) \cdot \log \left(1 - h_{\theta} \left(x^{(i)} \right) \right) \right]$$

Muốn $\min_{\theta} (J(\theta))$

- Thuật toán

- Chọn một điểm bất kỳ $\theta = (\theta_0, \theta_1, \dots, \theta_n)^T$
- Thực hiện liên tiếp các phép biến đổi

$$\theta_j := \theta_j - \alpha \cdot \frac{dJ(\theta, x^{(i)}, y^{(i)})}{d\theta_j}$$

- Thuật toán dừng khi $J(\theta)$ thay đổi rất nhỏ

Tối ưu hàm mất mát (tiếp)

- $J(\theta, x^{(i)}, y^{(i)}) = -[y^{(i)} \cdot \log(h_\theta(x^{(i)})) + (1 - y^{(i)}) \cdot \log(1 - h_\theta(x^{(i)}))]$
- $\frac{dJ(\theta, x^{(i)}, y^{(i)})}{d\theta_j} = ?$

- $\frac{dJ(\theta, x^{(i)}, y^{(i)})}{d\theta_j} = \frac{dJ(\theta, x^{(i)}, y^{(i)})}{dh_\theta} \cdot \frac{dh_\theta}{dx^{(i)}} \cdot \frac{dx^{(i)}}{d\theta_j}$
- $\frac{dJ(\theta, x^{(i)}, y^{(i)})}{dh_\theta} = -\left(\frac{y^{(i)}}{h_\theta(x^{(i)})} - \frac{1 - y^{(i)}}{1 - h_\theta(x^{(i)})}\right) = \frac{h_\theta(x^{(i)}) - y^{(i)}}{h_\theta(x^{(i)})(1 - h_\theta(x^{(i)}))}$
- $\frac{dh_\theta}{dx^{(i)}} = h_\theta(x^{(i)})(1 - h_\theta(x^{(i)}))$
- $\frac{dx^{(i)}}{d\theta_j} = x_j^{(i)}$

====>

$$\frac{dJ(\theta, x^{(i)}, y^{(i)})}{d\theta_j} = (h_\theta(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}$$

Demo

```
def logistic_sigmoid_regression(X, y, w_init, alpha, tol = 1e-4, loop = 10000):  
    w = [w_init]  
    N = X.shape[1]  
    d = X.shape[0]  
    count = 0  
    check_w = 20  
    while count < loop:  
        # mix data  
        mix_id = np.random.permutation(N)  
        for i in mix_id:  
            xi = X[:, i].reshape(d, 1)  
            yi = y[i]  
            zi = sigmoid(np.dot(w[-1].T, xi))  
            w_new = w[-1] + alpha*(yi - zi)*xi  
            count += 1  
        # stopping criteria  
        if count%check_w == 0:  
            if np.linalg.norm(w_new - w[-check_w]) < tol:  
                return w  
            w.append(w_new)  
    return w
```

Bài tập 1

- Cài đặt

- Chọn một điểm bất kỳ $\theta = (\theta_0, \theta_1, \dots, \theta_n)^T$
- Thực hiện liên tiếp các phép biến đổi

$$\theta_j := \theta_j - \alpha \cdot \frac{dJ(\theta)}{d\theta_j}$$

- Thuật toán dừng khi $J(\theta)$ thay đổi rất nhỏ

- HD

$$\cdot \frac{dJ(\theta)}{d\theta_j} = \frac{dJ}{dh_\theta} \cdot \frac{dh_\theta}{dx^{(i)}} \cdot \frac{dx^{(i)}}{d\theta_j}$$

$$\cdot \frac{dJ}{dh_\theta} = -\frac{1}{m} \sum_{i=1}^m \left(\frac{y^{(i)}}{h_\theta(x^{(i)})} - \frac{1-y^{(i)}}{1-h_\theta(x^{(i)})} \right) = \frac{1}{m} \sum_{i=1}^m \frac{h_\theta(x^{(i)}) - y^{(i)}}{h_\theta(x^{(i)})(1-h_\theta(x^{(i)}))}$$

$$\cdot \frac{dh_\theta}{dx^{(i)}} = h_\theta(x^{(i)}) (1 - h_\theta(x^{(i)}))$$

$$\cdot \frac{dx^{(i)}}{d\theta_j} = x_j^{(i)}$$

$$\frac{dJ(\theta)}{d\theta_j} = \frac{1}{m} \sum_{i=1}^m \left(h_\theta(x^{(i)}) - y^{(i)} \right) \cdot x_j^{(i)}$$

Bài tập 2

- Thực nghiệm phân loại hoa Iris setosa và Iris virginica
- Dữ liệu mẫu

Độ dài đài hoa	Độ rộng đài hoa	Độ dài cánh hoa	Độ rộng cánh hoa	Tên loài
5.1	3.5	1.4	0.2	Iris setosa
4.9	3	1.4	0.2	Iris setosa
4.7	3.2	1.3	0.2	Iris setosa
4.6	3.1	1.5	0.2	Iris setosa
5	3.6	1.4	0.2	Iris setosa
5.4	3.9	1.7	0.4	Iris setosa
4.6	3.4	1.4	0.3	Iris setosa
5	3.4	1.5	0.2	Iris setosa
4.4	2.9	1.4	0.2	Iris setosa
4.9	3.1	1.5	0.1	Iris setosa
6.3	3.3	6	2.5	Iris virginica
5.8	2.7	5.1	1.9	Iris virginica
7.1	3	5.9	2.1	Iris virginica
6.3	2.9	5.6	1.8	Iris virginica
6.5	3	5.8	2.2	Iris virginica
7.6	3	6.6	2.1	Iris virginica
4.9	2.5	4.5	1.7	Iris virginica
7.3	2.9	6.3	1.8	Iris virginica
6.7	2.5	5.8	1.8	Iris virginica
7.2	3.6	6.1	2.5	Iris virginica

Tài liệu tham khảo

1. <https://realpython.com/logistic-regression-python/#single-variate-logistic-regression>
2. Andrew Ng + Logistic Regression:
<https://www.youtube.com/watch?v=-la3q9d7AKQ>